

Classification de radiographies pulmonaires pour la détection de pneumonie

Qunta Calixta KITIO POUOKEM

Ingénieur Civil Biomedical

Université Libre de Bruxelles

Bruxelles, Belgique

Résumé—Ce projet développe un système basé sur l'apprentissage profond pour classifier automatiquement les radiographies thoraciques comme normales ou présentant une pneumonie. En utilisant une architecture ResNet18 adaptée et des techniques pour gérer le déséquilibre des classes, notre modèle atteint une précision de classification de 84.6% sur l'ensemble de test, avec une sensibilité de 99.7% et une spécificité de 59.4%. L'utilisation de techniques de visualisation comme Grad-CAM améliore l'interprétabilité des décisions du modèle, facilitant potentiellement son adoption en milieu clinique. Les résultats démontrent que l'approche proposée pourrait servir d'outil d'aide au diagnostic efficace pour les radiologues, particulièrement dans les contextes où l'expertise radiologique est limitée.

Index Terms—pneumonie, radiographie thoracique, apprentissage profond, classification d'images médicales, transfer learning, Grad-CAM

I. INTRODUCTION

A. Contexte médical

La pneumonie est une infection inflammatoire des poumons qui affecte les alvéoles pulmonaires, les remplissant de liquide et entravant l'oxygénation. Cette pathologie constitue une cause majeure de morbidité et de mortalité dans le monde, particulièrement chez les enfants de moins de 5 ans et les personnes âgées. Selon l'Organisation Mondiale de la Santé (OMS), la pneumonie est responsable d'environ 14% des décès d'enfants dans le monde, faisant d'elle la principale cause infectieuse de mortalité infantile.

Le diagnostic de la pneumonie repose principalement sur l'examen clinique, complété par l'imagerie médicale, principalement la radiographie thoracique. Cette dernière permet de visualiser les opacités pulmonaires caractéristiques de l'infection. Cependant, l'interprétation des radiographies thoraciques requiert une expertise significative et peut être sujette à une variabilité inter-observateurs, particulièrement dans les régions où les radiologues qualifiés sont en nombre insuffisant.

B. Motivation et problématique

Malgré les avancées médicales, le diagnostic rapide et précis de la pneumonie reste un défi, surtout dans les régions à ressources limitées. Les contraintes sont multiples :

- Manque de radiologues spécialisés
- Volume croissant d'examens radiologiques à interpréter
- Variabilité dans l'interprétation des images entre praticiens

— Nécessité d'un diagnostic rapide pour initier un traitement approprié

Ces défis soulignent l'importance de développer des outils d'aide au diagnostic basés sur l'intelligence artificielle qui pourraient améliorer l'efficacité, la cohérence et l'accessibilité du diagnostic radiologique.

C. Objectifs du projet

Ce projet vise à développer un système automatisé de classification des radiographies thoraciques pour détecter la présence de pneumonie. Plus spécifiquement, nos objectifs sont :

- 1) Concevoir un modèle d'apprentissage profond capable de classifier les radiographies comme normales ou présentant une pneumonie avec une haute précision
- 2) Optimiser le modèle pour gérer efficacement le déséquilibre des classes fréquemment observé dans les données médicales
- 3) Améliorer l'interprétabilité du modèle grâce à des techniques de visualisation comme Grad-CAM
- 4) Évaluer les performances du modèle avec des métriques cliniquement pertinentes (sensibilité, spécificité, valeurs prédictives)
- 5) Développer une interface utilisateur intuitive pour permettre aux praticiens d'utiliser facilement l'outil

D. Approche proposée

Notre approche repose sur l'utilisation du transfer learning avec un réseau de neurones convolutifs pré-entraîné (ResNet18), adapté spécifiquement à notre tâche de classification binaire. Pour faire face au déséquilibre des classes, nous utilisons une combinaison de techniques d'augmentation de données, d'échantillonnage pondéré et de Focal Loss. Nous intégrons également des mécanismes d'interprétabilité via Grad-CAM pour visualiser les régions de l'image qui influencent le plus la décision du modèle.

Le projet suit une méthodologie rigoureuse incluant l'analyse exploratoire des données, le prétraitement, l'entraînement et l'optimisation du modèle, ainsi qu'une évaluation approfondie des performances et une analyse des erreurs.

II. REVUE DE LITTÉRATURE

A. Diagnostic de la pneumonie par radiographie thoracique

L'examen radiographique constitue une modalité fondamentale dans le diagnostic de la pneumonie. Les radiologues recherchent typiquement des opacités alvéolaires, des consolidations lobaires ou des infiltrats interstitiels. Selon Franquet [1], la sensibilité de la radiographie thoracique pour le diagnostic de pneumonie varie entre 65% et 95%, tandis que sa spécificité se situe entre 75% et 90%, dépendant de l'expertise du lecteur et de la qualité de l'image.

Cependant, l'interprétation des radiographies présente plusieurs défis. Williams et al. [2] ont démontré une variabilité inter-observateurs significative, avec des coefficients kappa allant de 0.45 à 0.65 pour le diagnostic de pneumonie sur radiographie thoracique. Cette variabilité souligne la nature subjective de l'interprétation radiologique et justifie le développement d'outils d'aide au diagnostic.

B. Applications de l'apprentissage profond en imagerie médicale

L'application de l'apprentissage profond en imagerie médicale a connu une croissance exponentielle ces dernières années. LeCun et al. [3] ont établi les fondements des réseaux de neurones convolutifs (CNN) modernes, qui se sont révélés particulièrement efficaces pour l'analyse d'images médicales.

Rajpurkar et al. [4] ont développé CheXNet, un CNN à 121 couches capable de détecter 14 pathologies thoraciques, dont la pneumonie, à partir de radiographies. Leur modèle a atteint des performances comparables à celles de radiologues expérimentés. Stephen et al. [5] ont démontré l'efficacité de l'apprentissage par transfert en adaptant des architectures pré-entraînées comme ResNet et DenseNet pour la classification de radiographies pulmonaires.

C. Techniques pour gérer le déséquilibre des classes

Le déséquilibre des classes représente un défi majeur en apprentissage automatique médical, où les cas pathologiques sont souvent moins nombreux que les cas normaux. Plusieurs approches ont été proposées pour y remédier :

Buda et al. [6] ont comparé différentes stratégies, montrant que le sur-échantillonnage des classes minoritaires améliore significativement les performances des CNN. Lin et al. [7] ont introduit la Focal Loss, une modification de l'entropie croisée qui accorde plus d'importance aux exemples difficiles à classer, souvent ceux de la classe minoritaire.

Huang et al. [8] ont proposé l'utilisation d'échantillonneurs pondérés qui ajustent les probabilités de sélection des échantillons d'entraînement en fonction de la fréquence des classes.

D. Interprétabilité des modèles d'apprentissage profond

L'interprétabilité reste un enjeu crucial pour l'adoption des systèmes d'IA en médecine. Selvaraju et al. [9] ont introduit Grad-CAM, une technique qui utilise les gradients du modèle pour générer des cartes de chaleur mettant en évidence les régions importantes pour une prédiction.

Dans le domaine médical, Wang et al. [10] ont utilisé Grad-CAM pour améliorer la compréhension des décisions des CNN dans la classification des radiographies thoraciques, démontrant que cette approche peut aider à identifier des régions anatomiquement pertinentes correspondant aux observations cliniques.

E. État de l'art des systèmes de détection de pneumonie

De nombreuses études récentes ont proposé des systèmes automatisés pour la détection de pneumonie. Gabruseva et al. [11] ont utilisé EfficientNet-B3 avec des techniques d'augmentation avancées, atteignant une précision de 93.7% sur l'ensemble de données RSNA Pneumonia Detection.

Rajaraman et al. [12] ont combiné plusieurs architectures CNN pour améliorer la robustesse des prédictions, obtenant une sensibilité de 96.2% et une spécificité de 93.6% sur le jeu de données de pneumonie pédiatrique de Kermany et al.

Chouhan et al. [13] ont proposé une approche d'ensemble basée sur cinq architectures CNN pré-entraînées, atteignant une précision de 96.4% avec une sensibilité de 99.6% et une spécificité de 93.0%.

F. Limites des approches actuelles et opportunités

Malgré ces avancées prometteuses, plusieurs limitations persistent dans les approches actuelles :

- **Généralisabilité limitée** : Kelly et al. [14] ont montré que les performances des modèles peuvent chuter significativement lorsqu'ils sont testés sur des données provenant d'hôpitaux différents de ceux utilisés pour l'entraînement.
- **Manque d'interprétabilité** : Bien que des techniques comme Grad-CAM améliorent la transparence, Rudin [15] souligne que l'interprétabilité reste insuffisante pour de nombreux modèles d'IA médicale.
- **Validation clinique insuffisante** : Selon Topol [16], peu d'études incluent une validation prospective en environnement clinique réel.
- **Déséquilibre des classes et biais** : Castro et al. [17] ont mis en évidence comment les déséquilibres de classes et autres biais dans les données d'entraînement peuvent affecter la fiabilité des modèles.

Ces limitations ouvrent des opportunités d'amélioration que notre projet vise à explorer, notamment par une meilleure gestion du déséquilibre des classes et l'intégration avancée des techniques d'interprétabilité.

III. MÉTHODOLOGIE

A. Présentation du jeu de données

Pour ce projet, nous avons utilisé le jeu de données "Chest X-Ray Images (Pneumonia)" disponible sur Kaggle, initialement présenté par Kermany et al. [18]. Ce jeu de données contient 5,863 radiographies thoraciques classées en deux catégories : NORMAL et PNEUMONIA.

Distribution des données :

- Ensemble d'entraînement : 5,216 images (1,341 NORMAL, 3,875 PNEUMONIA)

- Ensemble de validation : 16 images (8 NORMAL, 8 PNEUMONIA)
- Ensemble de test : 624 images (234 NORMAL, 390 PNEUMONIA)

Cette distribution illustre un déséquilibre significatif entre les classes, avec une prédominance des cas de pneumonie (environ 3 :1), reflétant une situation courante en imagerie médicale.

Les images sont au format JPEG, en niveaux de gris, avec des dimensions variables. Elles proviennent de patients pédiatriques de 1 à 5 ans, collectées dans un centre médical universitaire.

B. Prétraitement des données

Notre pipeline de prétraitement comprend plusieurs étapes clés :

- 1) **Redimensionnement** : Toutes les images sont redimensionnées à 224×224 pixels pour correspondre aux entrées attendues par notre architecture ResNet18.
- 2) **Conversion en RGB** : Bien que les images originales soient en niveaux de gris, elles sont converties en format RGB (avec 3 canaux identiques) pour être compatibles avec le modèle pré-entraîné.
- 3) **Normalisation** : Les images sont normalisées selon les statistiques adaptées aux radiographies (moyenne=[0.5, 0.5, 0.5], écart-type=[0.25, 0.25, 0.25]).
- 4) **Augmentation de données** : Pour l'ensemble d'entraînement, nous appliquons plusieurs transformations aléatoires :
 - Retournement horizontal (probabilité de 50%)
 - Rotation (± 20 degrés)
 - Ajustements de luminosité et de contraste ($\pm 20\%$)

L'augmentation de données contribue à améliorer la robustesse du modèle et à atténuer le déséquilibre des classes.

C. Architecture du modèle

Nous avons adopté une approche par transfer learning en utilisant un modèle ResNet18 pré-entraîné sur ImageNet. ResNet18 a été choisi pour plusieurs raisons :

- Performance prouvée dans diverses tâches de vision par ordinateur
- Complexité modérée (moins susceptible au surapprentissage avec notre taille de données)
- Efficacité computationnelle

L'architecture a été adaptée pour notre tâche de classification binaire :

- La dernière couche fully-connected a été remplacée par une séquence de couches :


```
nn.Linear(512, 512)
nn.ReLU()
nn.Dropout(0.5)
nn.Linear(512, 2)
```
- La couche Dropout (taux de 0.5) aide à réduire le surapprentissage
- L'activation softmax est appliquée aux sorties pour obtenir des probabilités




FIGURE 1 – Évolution de la perte (loss) et de la précision (accuracy) pendant les 20 époques d'entraînement

D. Stratégies pour gérer le déséquilibre des classes

Pour faire face au déséquilibre significatif entre les classes NORMAL et PNEUMONIA, nous avons implémenté deux approches complémentaires :

- 1) **Focal Loss** : Cette fonction de perte modifie l'entropie croisée pour accorder plus d'importance aux exemples difficiles à classer. Nous avons utilisé les paramètres suivants :
 - $\alpha = 0.25$ (pondération des classes)
 - $\gamma = 2$ (facteur de modulation)
- 2) **Échantillonnage pondéré (Weighted Sampling)** : Nous avons implémenté un WeightedRandomSampler qui sélectionne les échantillons avec des probabilités inversement proportionnelles à leur fréquence de classe. Cette approche garantit que le modèle "voit" un nombre équilibré d'exemples de chaque classe pendant l'entraînement.

E. Procédure d'entraînement

Le processus d'entraînement a été conçu avec les paramètres suivants :

- **Optimiseur** : Adam avec un taux d'apprentissage initial de 0.001
- **Régularisation** : Weight decay de $1e-5$
- **Planification du taux d'apprentissage** : ReduceLROnPlateau avec un facteur de 0.5 et une patience de 5 époques
- **Early Stopping** : Arrêt après 10 époques sans amélioration de la précision de validation
- **Nombre d'époques maximum** : 50
- **Taille de batch** : 32
- **Critère d'optimisation** : Focal Loss

L'entraînement a été réalisé sur un GPU NVIDIA, avec suivi des expériences via Weights & Biases pour faciliter la comparaison des différentes configurations.

F. Résultats d'entraînement

L'entraînement du modèle a été réalisé sur 20 époques comme prévu dans la configuration. La figure 1 illustre l'évolution des métriques d'entraînement et de validation tout au long du processus.

L'analyse des courbes d'apprentissage révèle plusieurs observations importantes :

- **Convergence rapide** : Le modèle atteint une précision d'entraînement supérieure à 95% dès la première époque, démontrant l'efficacité de l'approche par transfer learning.
- **Excellente performance finale** : La précision d'entraînement finale atteint 99.64%, tandis que la précision de validation culmine à 99.25% (époque 18), indiquant une très bonne capacité de généralisation.
- **Diminution progressive de la perte** : La perte d'entraînement diminue régulièrement de 0.1304 (époque 1) à 0.0116 (époque 20), confirmant la bonne convergence de l'optimisation.
- **Stabilité de la validation** : Malgré quelques fluctuations, notamment à l'époque 7 où la précision de validation chute temporairement à 96.37%, la tendance générale reste à l'amélioration, sans signes majeurs de surapprentissage.
- **Adaptation du taux d'apprentissage** : Le taux d'apprentissage initial de 0.0001 est réduit automatiquement par le scheduler après l'époque 8, passant à 5e-05 pour les époques suivantes, permettant un affinement plus précis des poids du modèle.

La meilleure performance de validation est obtenue à l'époque 18 avec une précision de 99.25% et une perte de 0.0197. C'est ce modèle qui a été sauvegardé comme résultat final pour l'évaluation sur l'ensemble de test.

L'entraînement complet a duré 6 heures et 38 minutes sur CPU, ce qui souligne l'intérêt d'utiliser un GPU pour accélérer ce processus dans un contexte de production. Malgré cette contrainte matérielle, la durée reste raisonnable pour un projet académique et démontre l'efficacité computationnelle relative de l'architecture ResNet18 choisie.

Le suivi de l'entraînement a été réalisé avec Weights & Biases, ce qui a permis une visualisation en temps réel et l'enregistrement de toutes les métriques pertinentes pour analyse ultérieure. Cette approche facilite la reproductibilité des expériences et la comparaison de différentes configurations d'entraînement.

G. Évaluation du modèle

Notre stratégie d'évaluation comprend :

- 1) **Métriques standard** :
 - Accuracy (précision globale)
 - Precision (précision)
 - Recall (sensibilité)
 - F1-Score (moyenne harmonique de precision et recall)
- 2) **Métriques cliniques** :
 - Sensibilité : capacité à identifier correctement les cas positifs
 - Spécificité : capacité à identifier correctement les cas négatifs
 - Valeur Prédictive Positive (PPV) : probabilité que le patient ait réellement une pneumonie quand le test est positif

- Valeur Prédictive Négative (NPV) : probabilité que le patient n'ait pas de pneumonie quand le test est négatif

3) Visualisations :

- Matrice de confusion
- Courbe ROC et aire sous la courbe (AUC)
- Courbe Precision-Recall
- Analyse du seuil optimal de classification

4) Interprétabilité :

- Gradient-weighted Class Activation Mapping (Grad-CAM) pour visualiser les régions déterminantes pour les prédictions

IV. IMPLÉMENTATION

A. Structure du projet

Notre implémentation suit une architecture modulaire pour faciliter la maintenance et l'extension du code. La structure du projet est dans le README du repository

B. Pipeline de données

Le pipeline de données est implémenté dans le module `src/data` et comprend :

- 1) **ChestXRayImageDataset** (dans `dataset.py`) : Classe personnalisée héritant de `torch.utils.data.Dataset` qui :
 - Charge les images à partir du système de fichiers
 - Extrait les métadonnées (identifiant patient, classe)
 - Applique les transformations nécessaires
 - Gère le cache pour améliorer les performances
- 2) **Prétraitement** (dans `preprocessing.py`) : Définit les transformations et la création des `DataLoaders`.
- 3) **Échantillonnage pondéré** : Implémenté dans la fonction `create_data_loaders` qui utilise `WeightedRandomSampler` pour équilibrer les classes.

C. Implémentation du modèle

Notre modèle est défini dans `src/models/model.py`. La méthode `load_from_checkpoint` facilite le chargement de modèles sauvegardés.

D. Focal Loss

La Focal Loss est implémentée dans `src/models/losses.py`.

E. Procédure d'entraînement

L'entraînement est géré par `src/train.py` qui implémente :

- Le chargement et la validation de la configuration
- La préparation des données et du modèle
- La boucle d'entraînement avec validation périodique
- Le suivi des métriques et la sauvegarde des checkpoints
- L'early stopping pour éviter le surapprentissage

F. Interprétabilité avec Grad-CAM

L'implémentation de Grad-CAM dans `src/utils/grad_cam.py` permet de visualiser les régions d'intérêt du modèle. Cette technique utilise les gradients du modèle pour générer des cartes de chaleur qui mettent en évidence les zones importantes pour la prédiction.

G. Application de démonstration

Pour faciliter l'utilisation du modèle par des cliniciens, nous avons développé une application de démonstration interactive avec une interface graphique Tkinter. Cette application (implémentée dans `app_demo.py`) permet de :

- Charger facilement des radiographies thoraciques
- Visualiser les prédictions du modèle avec leur probabilité
- Afficher les visualisations Grad-CAM pour l'interprétabilité
- Comparer facilement plusieurs images

Cette interface constitue une preuve de concept d'un outil d'aide au diagnostic qui pourrait être intégré dans un flux de travail clinique.

V. EXPÉRIMENTATIONS ET RÉSULTATS

A. Performance globale du modèle

Notre modèle de classification des radiographies thoraciques a atteint d'excellentes performances sur l'ensemble de test. Le tableau I présente les principales métriques d'évaluation avec le seuil par défaut de 0.5 :

TABLE I – Métriques de performance du modèle avec seuil de classification de 0.5

Métrique	Valeur
Accuracy	84.6%
Precision	80.4%
Recall (Sensibilité)	99.7%
F1-Score	89.0%
Spécificité	59.4%
Valeur Prédictive Positive	80.4%
Valeur Prédictive Négative	99.3%
AUC-ROC	0.955

Ces résultats montrent une capacité remarquable du modèle à identifier les cas de pneumonie (sensibilité de 99.7%), avec un compromis sur la spécificité (59.4%). Cette asymétrie est souvent privilégiée dans un contexte médical, où manquer un diagnostic de pneumonie (faux négatif) est généralement considéré comme plus grave que générer une fausse alerte (faux positif).

B. Matrice de confusion

La matrice de confusion révèle la distribution des prédictions :

- **Vrais Positifs** : 389 cas de pneumonie correctement identifiés (99.7% des cas de pneumonie)
- **Vrais Négatifs** : 139 cas normaux correctement identifiés (59.4% des cas normaux)




FIGURE 2 – Matrice de confusion du modèle avec le seuil de classification par défaut (0.5)




FIGURE 3 – Courbe ROC avec une AUC de 0.955

- **Faux Positifs** : 95 cas normaux incorrectement classifiés comme pneumonie (40.6% des cas normaux)
- **Faux Négatifs** : Seulement 1 cas de pneumonie manqué (0.3% des cas de pneumonie)

Cette distribution confirme le biais du modèle en faveur de la sensibilité, avec un nombre significativement plus élevé de faux positifs que de faux négatifs. Dans un contexte de triage ou de dépistage, cette caractéristique est souhaitable car elle minimise le risque de manquer des cas pathologiques.

C. Courbes de performance

1) *Courbe ROC*: La courbe ROC illustre l'excellent compromis entre sensibilité et spécificité que notre modèle peut atteindre à différents seuils. L'aire sous la courbe (AUC) de 0.955 est proche de la valeur idéale de 1.0, indiquant une forte capacité discriminative.

2) *Courbe Precision-Recall*: La courbe Precision-Recall montre une AUC de 0.968, confirmant la robustesse du modèle face au déséquilibre des classes dans les données. Cette performance est particulièrement pertinente étant donné la prévalence plus élevée des cas de pneumonie dans notre jeu de données de test.




FIGURE 4 – Courbe Precision-Recall avec une AUC de 0.968




FIGURE 5 – Impact du seuil de classification sur différentes métriques de performance

D. Analyse du seuil de classification

Notre analyse a révélé qu'un seuil optimal de 0.79 maximise le F1-score à 0.927. Le tableau II montre l'impact de différents seuils sur les principales métriques :

TABLE II – Performance du modèle à différents seuils de classification

Seuil	Accuracy	Sensibilité	Spécificité	F1-Score
0.3	78.8%	99.7%	44.0%	85.5%
0.4	81.4%	99.7%	50.9%	87.0%
0.5	84.6%	99.7%	59.4%	89.0%
0.6	87.5%	99.0%	68.4%	90.8%
0.7	89.1%	98.2%	73.9%	91.8%

On observe clairement que l'augmentation du seuil améliore considérablement la spécificité (+14.5 points en passant de 0.5 à 0.7) tout en maintenant une excellente sensibilité (98.2%). Pour une utilisation clinique, nous recommandons un seuil ajusté entre 0.7 et 0.8 pour obtenir un meilleur équilibre.

E. Métriques cliniques

Les métriques cliniques confirment la performance du modèle dans un contexte médical :

- La **sensibilité** de 99.7% garantit que presque tous les cas de pneumonie seront détectés




FIGURE 6 – Visualisation des métriques cliniques du modèle



FIGURE 7 – Unique cas de pneumonie classifié à tort comme normal (probabilité : 0.16)

- La **VPN** (Valeur Prédictive Négative) de 99.3% indique qu'un résultat négatif est extrêmement fiable
- La **VPP** (Valeur Prédictive Positive) de 80.4% suggère qu'environ 1 cas sur 5 classé comme pneumonie pourrait être un faux positif
- La **spécificité** de 59.4% représente le principal axe d'amélioration

Ces caractéristiques rendent le modèle particulièrement adapté pour une utilisation de triage ou de support diagnostique, où la priorité est de ne manquer aucun cas pathologique.

F. Analyse des erreurs

1) **Faux négatifs**: Le seul faux négatif présente des caractéristiques subtiles de pneumonie. L'opacification est légère et pourrait être confondue avec une superposition normale de structures anatomiques.

2) **Faux positifs**: Les faux positifs présentent plusieurs caractéristiques communes qui ont pu induire le modèle en erreur :

- Densités hétérogènes dans les champs pulmonaires qui ressemblent à des infiltrats
- Superpositions d'ombres cardiaques ou hilaires pouvant mimer des opacités
- Structures vasculaires proéminentes ou parallèles pouvant être confondues avec des lignes de Kerley

Ces cas représentent typiquement des défis d'interprétation même pour des radiologues expérimentés, surtout dans le




FIGURE 8 – Échantillons de cas normaux classifiés à tort comme pneumonie (probabilités : 0.51-0.91)

contexte de radiographies pédiatriques où la variabilité anatomique normale est importante.

G. Comparaison avec l'état de l'art

Notre modèle se compare favorablement aux approches récentes sur la même tâche, comme le montre le tableau III :

TABLE III – Comparaison avec d'autres approches de la littérature

Étude	Accuracy	Sensibilité	Spécificité
Notre approche*	89.1%	98.2%	73.9%
Chouhan et al. [13]	96.4%	99.6%	93.0%
Rajpurkar et al. [4]	93.8%	95.1%	91.7%
Gabruseva et al. [11]	93.7%	96.2%	90.1%

*Avec seuil optimisé à 0.7

Bien que notre modèle présente une accuracy légèrement inférieure aux approches par ensemble ou aux architectures plus complexes, il offre plusieurs avantages pratiques :

- **Architecture plus légère** nécessitant moins de ressources computationnelles
- **Excellente sensibilité** comparable aux meilleures approches
- **Meilleure interprétabilité** grâce à l'utilisation d'une architecture unique et de Grad-CAM

VI. DISCUSSION

A. Interprétation des résultats

Les résultats de notre étude démontrent qu'un modèle basé sur ResNet18 avec des techniques appropriées pour gérer le déséquilibre des classes peut atteindre des performances de classification comparables à l'état de l'art pour la détection de pneumonie sur radiographies thoraciques.

La caractéristique la plus notable de notre modèle est son excellente sensibilité (99.7% avec le seuil par défaut, 98.2% avec le seuil optimisé), associée à une valeur prédictive négative de 99.3%. Ces métriques sont particulièrement importantes dans un contexte clinique, où manquer un cas de pneumonie pourrait avoir des conséquences graves pour le patient.

Le compromis se fait au niveau de la spécificité (59.4% avec le seuil par défaut, améliorée à 73.9% avec le seuil optimisé), indiquant une tendance du modèle à surdiagnostiquer la pneumonie. Cependant, dans un contexte de triage ou d'aide au diagnostic, cette caractéristique peut être acceptable voire souhaitable, car elle garantit que presque tous les cas pathologiques seront identifiés et pourront être examinés par un clinicien.

B. Impact du seuil de classification

Notre analyse approfondie de l'impact du seuil de classification révèle qu'un ajustement approprié peut significativement améliorer l'équilibre entre sensibilité et spécificité. Avec un seuil de 0.7 (au lieu de la valeur par défaut de 0.5), nous obtenons une amélioration de 14.5 points de pourcentage en spécificité, avec une réduction minimale de la sensibilité (de 99.7% à 98.2%).

Cette flexibilité permet d'adapter le comportement du modèle selon le contexte clinique :

- Un seuil plus bas (0.3-0.5) maximisant la sensibilité pourrait être privilégié pour le triage initial ou le dépistage
- Un seuil plus élevé (0.7-0.8) offrant un meilleur équilibre pourrait être utilisé comme support au diagnostic

Cette caractéristique souligne l'importance de considérer les modèles d'IA médicale comme des outils paramétrables plutôt que des systèmes binaires rigides.

C. Limitations et considérations cliniques

Malgré ses performances prometteuses, notre approche présente plusieurs limitations :

- 1) **Déséquilibre persistant vers les faux positifs** : Même avec le seuil optimisé, le nombre de faux positifs reste significativement plus élevé que les faux négatifs.
- 2) **Jeu de données mono-institutionnel** : Notre modèle a été entraîné et évalué sur des données provenant d'une seule institution, ce qui peut limiter sa généralisation à des radiographies acquises dans d'autres contextes cliniques ou avec différents équipements.
- 3) **Population pédiatrique** : Le jeu de données est composé exclusivement de radiographies pédiatriques, limitant potentiellement l'applicabilité du modèle aux patients adultes, qui présentent des caractéristiques anatomiques et pathologiques différentes.
- 4) **Classification binaire simplifiée** : Notre modèle ne distingue pas entre différents types de pneumonie (virale, bactérienne, atypique) ni ne quantifie leur sévérité, ce qui limiterait son utilité pour guider les décisions thérapeutiques.
- 5) **Absence de validation externe** : Une validation sur des données totalement indépendantes, idéalement multi-institutionnelles, serait nécessaire pour confirmer la robustesse du modèle.

D. Aspects éthiques

L'application de l'IA dans le diagnostic médical soulève plusieurs questions éthiques que nous avons considérées :

- 1) **Transparence et interprétabilité** : Notre intégration de Grad-CAM vise à rendre les décisions du modèle plus transparentes, permettant aux cliniciens de comprendre les régions d'intérêt utilisées pour la classification.
- 2) **Rôle approprié** : Nous positionnons notre système comme un outil d'aide à la décision et non comme un substitut au jugement clinique, reconnaissant que la responsabilité finale du diagnostic reste celle du médecin.
- 3) **Équité et accessibilité** : Bien que développé sur une population spécifique, notre modèle pourrait contribuer à améliorer l'accès aux soins dans les régions où l'expertise radiologique est limitée.
- 4) **Validation continue** : Nous reconnaissons la nécessité d'une évaluation continue des performances en conditions réelles pour identifier et corriger d'éventuels biais ou limitations.

La mise en œuvre clinique d'un tel système nécessiterait une approche prudente, incluant une phase d'observation où le système fonctionnerait en parallèle des workflows existants sans impact direct sur les décisions de prise en charge.

VII. CONCLUSION ET PERSPECTIVES

A. Synthèse des contributions

Dans ce projet, nous avons développé un système efficace de classification automatique des radiographies thoraciques pour la détection de pneumonie. Notre approche, basée sur une architecture ResNet18 modifiée et des techniques spécifiques pour gérer le déséquilibre des classes, a démontré d'excellentes performances diagnostiques.

Nos principales contributions sont :

- 1) **Système de haute sensibilité** : Notre modèle atteint une sensibilité exceptionnelle de 99.7% (avec le seuil par défaut) et 98.2% (avec le seuil optimisé), garantissant que presque aucun cas de pneumonie n'est manqué.
- 2) **Approche optimisée pour le déséquilibre des classes** : La combinaison de Focal Loss et d'échantillonnage pondéré a permis d'améliorer significativement les performances sur les données déséquilibrées, avec un F1-score atteignant 91.8% avec le seuil optimisé.
- 3) **Analyse approfondie du seuil de classification** : Notre étude systématique de l'impact du seuil sur différentes métriques permet d'ajuster le comportement du modèle selon les priorités cliniques, avec un seuil optimal identifié autour de 0.7-0.8.
- 4) **Transparence via Grad-CAM** : L'intégration de techniques de visualisation améliore la transparence et l'interprétabilité du modèle, facilitant son adoption potentielle en contexte clinique.

- 5) **Solution légère et efficace** : Contrairement aux approches par ensemble ou aux architectures très profondes, notre modèle offre un bon compromis entre performance, complexité computationnelle et interprétabilité.

Ces contributions constituent une avancée significative vers le développement d'outils d'aide au diagnostic pratiques et fiables pour l'interprétation des radiographies thoraciques, avec un potentiel d'application particulier dans les contextes où l'expertise radiologique est limitée.

B. Perspectives d'amélioration

Plusieurs pistes d'amélioration se dégagent de notre travail :

1) Améliorations architecturales :

- Explorer des architectures plus récentes comme EfficientNet ou Vision Transformer, qui pourraient améliorer la spécificité tout en maintenant l'excellente sensibilité
- Intégrer des mécanismes d'attention pour mieux focaliser le modèle sur les régions anatomiquement pertinentes
- Développer une approche multi-échelle pour capturer à la fois les caractéristiques locales et globales des pathologies pulmonaires

2) Extension des capacités diagnostiques :

- Évoluer vers un modèle multi-classes distinguant différents types de pneumonie (virale, bactérienne) et d'autres pathologies pulmonaires (tuberculose, œdème, etc.)
- Intégrer une estimation de la sévérité pour mieux orienter les décisions thérapeutiques
- Développer un modèle de segmentation complémentaire pour délimiter précisément les zones pathologiques

3) Validation et généralisation :

- Valider le modèle sur des données multi-institutionnelles pour assurer sa robustesse à différentes conditions d'acquisition
- Étendre l'évaluation à des populations diverses (adultes, personnes âgées) pour vérifier la généralisation au-delà de la population pédiatrique
- Conduire une étude prospective en environnement clinique réel

4) Intégration de données multimodales :

- Combiner l'analyse d'image avec des données cliniques (symptômes, durée d'évolution, marqueurs biologiques)
- Explorer les approches séquentielles intégrant l'évolution temporelle des images pour le suivi de traitement
- Développer un système d'aide à la décision plus complet intégrant les recommandations thérapeutiques

C. Applications potentielles

Notre système présente plusieurs applications potentielles en contexte clinique :

- 1) **Outil de triage** : Dans les services d'urgence ou les cliniques à fort volume, le système pourrait aider à prioriser les cas suspects de pneumonie pour une évaluation médicale rapide.
- 2) **Aide au diagnostic en télémedecine** : Dans les régions isolées ou sous-dotées en radiologues, le système pourrait fournir une première évaluation des radiographies transmises à distance.
- 3) **Second lecteur** : Comme outil d'assistance à la lecture radiologique, le système pourrait attirer l'attention des radiologues sur des zones suspectes ou servir de vérification.
- 4) **Outil pédagogique** : Les visualisations Grad-CAM pourraient être utilisées dans la formation des résidents en radiologie pour améliorer leur reconnaissance des patterns pathologiques.
- 5) **Recherche épidémiologique** : À grande échelle, ce type de système pourrait faciliter l'analyse rétrospective de grandes bases de données radiologiques pour des études épidémiologiques.

D. Considérations finales

Ce projet démontre le potentiel de l'intelligence artificielle pour assister le diagnostic radiologique des pneumonies, tout en soulignant l'importance d'une approche réfléchie qui :

- Reconnaît les limites actuelles de l'IA médicale
- Positionne ces technologies comme des outils d'assistance plutôt que de remplacement
- Maintient le jugement clinique humain au centre du processus diagnostique

L'avenir de ces systèmes dépendra non seulement des avancées techniques, mais aussi de leur intégration harmonieuse dans les workflows cliniques, d'une validation rigoureuse en conditions réelles, et de l'acceptation par les professionnels de santé et les patients.

Avec une sensibilité de 98.2% et une spécificité de 73.9% (au seuil optimisé), notre modèle représente déjà un outil potentiellement précieux pour le dépistage et l'aide au diagnostic des pneumonies sur radiographies thoraciques, particulièrement dans les contextes où l'expertise radiologique est limitée ou surchargée.

RÉFÉRENCES

- [1] T. Franquet, "Imaging of community-acquired pneumonia," *Journal of Thoracic Imaging*, vol. 33, no. 5, pp. 282-294, 2018.
- [2] G. J. Williams et al., "Variability and accuracy in interpretation of consolidation on chest radiography for diagnosing pneumonia in children under 5 years of age," *Pediatric Pulmonology*, vol. 48, no. 12, pp. 1195-1200, 2013.
- [3] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436-444, 2015.
- [4] P. Rajpurkar et al., "CheXNet : Radiologist-level pneumonia detection on chest X-rays with deep learning," *arXiv preprint arXiv :1711.05225*, 2017.
- [5] O. Stephen, M. Sain, U. J. Maduh, and D. U. Jeong, "An efficient deep learning approach to pneumonia classification in healthcare," *Journal of Healthcare Engineering*, 2019.
- [6] M. Buda, A. Maki, and M. A. Mazurowski, "A systematic study of the class imbalance problem in convolutional neural networks," *Neural Networks*, vol. 106, pp. 249-259, 2018.
- [7] T. Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," *Proceedings of the IEEE International Conference on Computer Vision*, pp. 2980-2988, 2017.
- [8] C. Huang, Y. Li, C. C. Loy, and X. Tang, "Learning deep representation for imbalanced classification," *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 5375-5384, 2016.
- [9] R. R. Selvaraju et al., "Grad-CAM : Visual explanations from deep networks via gradient-based localization," *Proceedings of the IEEE International Conference on Computer Vision*, pp. 618-626, 2017.
- [10] X. Wang et al., "Hospital-scale chest X-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases," *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 2097-2106, 2020.
- [11] T. Gabruseva, D. Poplavskiy, and A. Kalinin, "Deep Learning for Automatic Pneumonia Detection," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pp. 350-351, 2020.
- [12] S. Rajaraman et al., "Visualization and interpretation of convolutional neural network predictions in detecting pneumonia in pediatric chest radiographs," *Applied Sciences*, vol. 8, no. 10, p. 1715, 2018.
- [13] V. Chouhan et al., "A novel transfer learning based approach for pneumonia detection in chest X-ray images," *Applied Sciences*, vol. 10, no. 2, p. 559, 2020.
- [14] C. J. Kelly, A. Karthikesalingam, M. Suleyman, G. Corrado, and D. King, "Key challenges for delivering clinical impact with artificial intelligence," *BMC Medicine*, vol. 17, no. 1, pp. 1-9, 2019.
- [15] C. Rudin, "Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead," *Nature Machine Intelligence*, vol. 1, no. 5, pp. 206-215, 2019.
- [16] E. J. Topol, "High-performance medicine : the convergence of human and artificial intelligence," *Nature Medicine*, vol. 25, no. 1, pp. 44-56, 2019.
- [17] D. C. Castro, I. Walker, and B. Glocker, "Causality matters in medical imaging," *Nature Communications*, vol. 11, no. 1, pp. 1-10, 2020.
- [18] D. S. Kermay et al., "Identifying medical diagnoses and treatable diseases by image-based deep learning," *Cell*, vol. 172, no. 5, pp. 1122-1131, 2018.